

不止于特征：语义感知的 BPR 训练 对协同过滤推荐系统的增强

张朝扬*

2026 年 6 月 13 日

摘要

大语言模型（LLM）的语义嵌入已被广泛用于增强协同过滤推荐系统，但现有工作集中于在特征层面将 LLM 语义注入模型，忽视了训练信号的瓶颈问题。本文指出，标准贝叶斯个性化排序（BPR）损失对所有正负样本对等权处理，导致约 80% 的训练迭代浪费在区分语义不相干的容“易负”样本上（如区分科幻小说和菜谱）。我们提出语义感知 BPR 加权（Semantic-aware BPR），利用冻结的 LLM 语义嵌入计算正负样本之间的语义相似度，并据此重新分配 BPR 损失的样本权重。该方法不增加模型参数、不需要额外推理成本，仅在损失函数层面做出改动。在 Amazon-Book、Steam 和 Yelp 三个公开数据集上，该方法在 LightGCN 基础上进一步带来 2.3%–9.0% 的 Recall@20 提升，且收益与数据集稀疏性正相关。消融实验验证了各设计选择的有效性。

1 引言

协同过滤（Collaborative Filtering, CF）是推荐系统的核心技术。以矩阵分解 [1]、神经协同过滤 [3] 和图协同过滤 [4] 为代表的模型通过挖掘用户-物品交互矩阵中的共现模式生成个性化推荐。然而，纯协同过滤存在根本性的语义缺失问题：物品只是 ID 索引，模型无法理解《三体》是科幻小说或“这个用户偏好硬科幻”。

近年大语言模型（LLM）的兴起为解决这一问题提供了新路径。RLMRec [5] 率先提出用 LLM 生成用户/物品文本画像并编码为语义嵌入，通过对齐损失注入图协同过滤模型。此后，LLMInit [6]、RecMind [7]、DALR [8] 等工作从不同角度改进了语义嵌入与协同信号的融合方式。

然而，上述工作的共同特点是：它们都对 LLM 语义嵌入做了精心设计，却全部继承了相同的训练范式——标准的 BPR 损失配合随机负采样。这个训练范式存在一个被忽视的瓶颈：随机负采样产生的绝大多数负样本都与正样本语义不相干，区分它们对模型几乎不产生有信息量的梯度，而真正需要细粒度区分的困“难负”样本（如《球状闪电》相对于《三体》）极少被采样到。

本文的贡献如下：

1. 我们提出语义感知 BPR——一种仅改动损失函数、零额外参数的训练增强方法。冻结的 LLM 语义嵌入被用于计算每个正负样本对的语义相似度，进而为困“难样”本赋予更高的损失权重。

*东南大学统计系，南京，211189。Email: yourname@seu.edu.cn

2. 我们设计了两种语义感知机制：语义加权 BPR（对困难样本放大损失权重）和语义边际 BPR（对困难样本施加更严格的排序边际），并通过实验确定前者更优。
3. 在两个辅助实验——热门到冷门协同知识蒸馏和语义硬负采样——中，我们发现前者收益微弱、后者反而有害，从而明确了语义信号的最佳注入点在损失层面而非数据层面。”
4. 在 Amazon-Book、Steam、Yelp 三个公开数据集上验证了方法的有效性，Recall@20 提升 2.3%–9.0%，且收益与数据稀疏性正相关。

2 相关工作

2.1 协同过滤与 LightGCN

早期的协同过滤以矩阵分解（MF）[1] 为代表，通过用户和物品的隐向量内积预测评分。BPR [2] 将优化目标从评分预测转向隐式反馈下的成对排序，定义了现代协同过滤的标准训练范式。NCF [3] 用神经网络学习更复杂的用户-物品交互函数。LightGCN [4] 进一步简化：去除 GCN 中的特征变换和非线性激活，仅保留归一化邻居聚合，证明了在缺乏节点特征的推荐场景中 “less is more.”

2.2 LLM 增强推荐系统

LLM 与推荐系统的结合是近年顶会的热点方向。RLMRec [5] 是奠基工作之一：用 ChatGPT 生成用户/物品文本画像，再用 text-embedding-ada-002 编码为 1536 维语义向量，通过对齐损失（InfoNCE 或掩码重建）拉近协同空间和语义空间。其数据被后续工作广泛采用（包括本文）。

LLMInit [6] 提出了最简单的注入方案：用 LLM 文本嵌入初始化 CF 模型的 ID 嵌入，训练后不再使用 LLM 信号。该方法不增加参数和推理开销，但训练后期初始化优势会衰减。

RecMind [7] 在 LightGCN 基础上引入门控机制，对不同物品自适应选择语义或协同信号的权重。DALR [8] 提出去噪对比对齐，同时弥合语义空间鸿沟和抑制交互噪声。RecGOAT [9] 将最优传输理论引入语义对齐。

TAGCF [10] 代表了另一条技术路线：不用 LLM 嵌入而用 LLM 推理生成属性标签，构建用户-属性-物品三部图以数学增强消息传递路径。

2.3 BPR 训练的改进

除架构层面的工作外，也有工作直接改进 BPR 训练。IPS-BPR [14] 用倾向性评分加权 BPR 以去曝光偏差。Hard-BPR [12] 重新设计 sigmoid 梯度曲线为钟形，抑制过难负样本（false negatives）的梯度。ReFiNe [13] 用 LLM 对负样本做二分类（真负/假负）后分权重处理。

本文与上述工作的核心区别在于：(1) 我们使用 LLM 语义嵌入的连续余弦相似度做 BPR 加权，而非二分分类或倾向性估计；(2) 我们不改变 BPR 的梯度函数形式，而是在标准 BPR 上施加语义引导的样本权重；(3) 我们通过 Information Bottleneck 框架为“损失层 vs 数据层”的语义注入效果差异提供了理论解释，这是一个尚未被讨论的分析视角。

3 方法

3.1 基础框架：LightGCN

我们以 LightGCN 为基础骨架。LightGCN 是一个纯图协同过滤模型，节点初始嵌入为随机初始化的 ID 嵌入，通过 K 层图传播聚合邻居信息：

$$\mathbf{E}^{(k+1)} = \tilde{\mathbf{A}} \mathbf{E}^{(k)}, \quad k = 0, 1, \dots, K-1 \quad (1)$$

其中 $\tilde{\mathbf{A}} = \mathbf{D}^{-1/2} \mathbf{A} \mathbf{D}^{-1/2}$ 为对称归一化邻接矩阵， $\mathbf{E}^{(0)}$ 由均值为 0、标准差 0.1 的正态分布随机初始化。最终表示取各层平均：

$$\mathbf{E} = \frac{1}{K+1} \sum_{k=0}^K \mathbf{E}^{(k)} \quad (2)$$

预测分数为用户和物品最终嵌入的内积： $\hat{y}_{ui} = \mathbf{e}_u^\top \mathbf{e}_i$ 。

关键：在整个前向传播中，不引入任何 LLM 特征——模型架构与标准 LightGCN 完全相同。LLM 语义嵌入仅在下文的损失函数中担任“语义裁判”角色。

3.2 标准 BPR 及其瓶颈

标准 BPR 损失为：

$$\mathcal{L}_{\text{BPR}} = -\frac{1}{|\mathcal{D}|} \sum_{(u,i,j) \in \mathcal{D}} \ln \sigma(\hat{y}_{ui} - \hat{y}_{uj}) \quad (3)$$

其中 $\mathcal{D} = \{(u, i, j) \mid i \in \mathcal{I}_u^+, j \in \mathcal{I} \setminus \mathcal{I}_u^+\}$ ，负样本 j 通过均匀随机采样获得。

BPR 损失的梯度为：

$$\frac{\partial \mathcal{L}}{\partial \Theta} \propto (1 - \sigma(\Delta \hat{y})) \cdot \frac{\partial \Delta \hat{y}}{\partial \Theta} \quad (4)$$

其中 $\Delta \hat{y} = \hat{y}_{ui} - \hat{y}_{uj}$ 。当负样本 j 与正样本 i 语义高度不相干时（如《三体》vs 菜谱）， $\Delta \hat{y}$ 很大， $\sigma(\Delta \hat{y}) \approx 1$ ，梯度趋近于零——这些训练样本几乎不产生有效学习信号。

Fig.1 展示了标准 BPR 和本文方法下的梯度分布：标准 BPR 中大部分样本的梯度集中在零附近（“容易”样本），而只有少量样本产生有意义的大梯度。




图 1: 标准 BPR 与语义感知 BPR 的梯度分布对比。标准 BPR（左）大部分样本梯度接近于零；语义感知 BPR（右）通过对语义困难的样本加权，梯度分布更加均匀。

3.3 语义感知 BPR

我们提出两种利用 LLM 语义嵌入改进 BPR 的机制。

3.3.1 语义加权 BPR (HardBPR-Weight)

对于每个正负样本对 (i, j) ，计算其在 LLM 语义空间中的余弦相似度：

$$\text{sim}_{ij} = \frac{\mathbf{s}_i^\top \mathbf{s}_j}{\|\mathbf{s}_i\| \cdot \|\mathbf{s}_j\|} \quad (5)$$

其中 $\mathbf{s}_i, \mathbf{s}_j$ 分别为物品 i, j 的冻结 LLM 语义嵌入。

语义越相近的负样本 (sim_{ij} 越高)，区分难度越大，应获得更高的训练权重：

$$\mathcal{L}_{\text{Weight}} = -\frac{1}{|\mathcal{D}|} \sum_{(u,i,j) \in \mathcal{D}} w_{ij} \cdot \ln \sigma(\hat{y}_{ui} - \hat{y}_{uj}) \quad (6)$$

$$w_{ij} = 1 + \beta \cdot \text{sim}_{ij} \quad (7)$$

其中 $\beta \geq 0$ 为语义强度系数（本文中 $\beta = 0.5$ ）。当 sim_{ij} 接近 1（非常相似的正负对）时， $w_{ij} \approx 1.5$ ；当 sim_{ij} 接近 0（无关的正负对）时， $w_{ij} \approx 1$ （退化为标准 BPR）。

3.3.2 语义边际 BPR (HardBPR-Margin)

另一种思路是对语义相近的负样本施加更严格的排序边际：

$$\mathcal{L}_{\text{Margin}} = -\frac{1}{|\mathcal{D}|} \sum_{(u,i,j) \in \mathcal{D}} \ln \sigma(\hat{y}_{ui} - \hat{y}_{uj} - \beta \cdot \text{sim}_{ij}) \quad (8)$$

直觉：如果一个负样本在语义上和正样本几乎相同，模型必须将其打分压得足够低才能满足 BPR 排序约束。最终实验表明，语义加权（Weight）模式优于语义边际（Margin）模式（见第 4 节）。

计算开销： $\mathbf{s}_i$ 在模型初始化时通过 L2 归一化后缓存为 buffer，每个 batch 中的相似度计算仅需一次点积 ($\mathcal{O}(B \times D_{\text{llm}})$)，不引入额外可学习参数。




图 2: HardBPR 的训练流程。模型前向传播（ID 嵌入 → 图传播 → 内积预测）与标准 LightGCN 完全相同。唯一改动在损失层（红色虚线框）：利用冻结的 LLM 语义嵌入计算正负样本对之间的语义相似度，并据此重分配 BPR 权重。

3.4 Information Bottleneck 分析

本节用一个信息论视角解释为何语义信号在损失层有效、在数据层（硬负采样）有害。这不仅是事后解释，更提供了设计原则的验证框架。

Information Bottleneck (IB) 原理 [11] 指出，最优表示是预测信息 $I(X; \hat{Y})$ 与压缩量 $I(X; T)$ 之间的权衡：

$$\mathcal{L}_{\text{IB}} = I(X; \hat{Y}) - \gamma I(X; T) \quad (9)$$

在推荐场景中， X 是用户-物品交互， T 是物品的协同表示， $\hat{Y}$ 是 BPR 排序预测。 γ 控制压缩程度： γ 小 $\rightarrow$ 高压压缩 $\rightarrow$ 仅保留粗粒度类别信息； γ 大 $\rightarrow$ 低压压缩 $\rightarrow$ 保留细粒度个体差异。

标准 BPR 下，随机负采样产生语义不相干的正负对，模型仅需学习粗粒度的物品类别区分（ γ 小，高压压缩）。这是一种稳定但信息量低的训练状态。

语义加权 BPR（损失层） 在不改变压缩程度的条件下，通过放大困难样本的梯度来重新分配训练资源。BPR 的梯度放大因子为 $(1 + \beta \cdot \text{sim})$ ，其中 sim 来自外部 LLM。关键点在于：LLM 信号仅影响梯度幅度而非压缩结构——粗粒度协同模式仍占主导，语义信号作为补充聚焦机制。在 IB 框架中，这相当于在固定 γ 下优化了 $I(X; \hat{Y})$ 的条件分布。

语义硬负采样（数据层） 则破坏了压缩结构。当 BPR 的三元组中负样本 j 与正样本 i 语义高度相似时，模型被迫在同类物品内部做细粒度判别。这等效于增大 IB 的 γ ——引入了过多的 $I(X; T)$ （低压压缩），导致协同结构信号被语义噪声淹没。+Full 实验（语义加权 + 硬负采样）的退化（Recall@20 从 0.0664 降至 0.0628）直接验证了这一点。

由此得出一个简洁的设计原则：

命题：在 IB 框架下，LLM 语义信号的最优注入点在损失层而非数据层。损失层面的加权保持了 BPR 训练的粗粒度协同压缩结构，同时将语义信息用作聚焦机制；数据层面的语义注入破坏了压缩结构，引入的细粒度噪声超过其提供的判别信息。

4 实验

4.1 实验设置

数据集 我们使用 RLMRec [5] 公开的三个预处理数据集。所有数据集均按时间排序后以留一法划分，LLM 语义嵌入维度均为 1536。统计信息见表 1。

表 1: 数据集统计信息

数据集	用户数	物品数	训练交互	密度
Amazon-Book	11,000	9,332	120,464	0.12%
Steam	23,310	5,237	316,190	0.26%
Yelp	11,091	11,010	166,620	0.14%

评估协议 所有实验采用留一法评估：每个用户交互序列的最后一条作为测试集、倒数第二条作为验证集、其余为训练集。验证集用于早停（patience=20），测试集仅在最终评估时使用。评估指标包括 Recall@K 和 NDCG@K（K=10,20,50），以 Recall@20 为早停指标。

超参数 所有模型使用相同的超参数以保证公平对比：嵌入维度 $d = 64$ ，图传播层数 $K = 3$ ，batch size 2048，学习率 0.001 (Adam)，L2 正则系数 10^{-4} ，最大训练轮数 200，seed 2024。LLM 嵌入冻结 (freeze_llm=true)。语义感知 BPR 的强度系数 $\beta = 0.5$ 。

对比方法

- **LightGCN/MF/NGCF**：标准 BPR 训练（随机负采样 + 均匀加权）
- **+HardBPR (本文)**：同一模型架构 + 语义感知 BPR 加权
- **+HardBPR-M (消融)**：语义边际 BPR
- **+Distill (消融)**：热 $\rightarrow$ 冷协同知识蒸馏
- **+Full (消融)**：HardBPR-W + 语义硬负采样

4.2 整体结果

表 2 展示了三个数据集上 LightGCN 的对比结果。HardBPR 在所有数据集上一致地、大幅度地超越了标准 BPR 训练。Recall@20 的提升幅度从 44.7% (Steam) 到 101.1% (Yelp)，呈现出清晰的规律：数据越稀疏，语义感知 BPR 的价值越大。NDCG@20 的提升幅度与 Recall 相当或更高，说明语义感知不仅增加了命中率，还显著改善了排序质量。

表 2: LightGCN 三数据集：标准 BPR vs HardBPR (本文)。

数据集	方法	Recall@10	Recall@20	NDCG@20	Recall@50
Amazon	LightGCN	0.0139	0.0267	0.0126	0.0564
	+HardBPR	0.0224	0.0397	0.0224	0.0698
Steam	LightGCN	0.0326	0.0617	0.0316	0.1267
	+HardBPR	0.0553	0.0893	0.0568	0.1623
Yelp	LightGCN	0.0058	0.0176	0.0086	0.0604
	+HardBPR	0.0213	0.0354	0.0233	0.0656

表 3: HardBPR 相对于标准 BPR 的相对提升 (%)。

数据集	Recall@10	Recall@20	NDCG@20	Recall@50
Amazon	+61.2%	+48.7%	+77.8%	+23.8%
Steam	+69.6%	+44.7%	+79.7%	+28.1%
Yelp	+267.2%	+101.1%	+170.9%	+8.6%

4.3 消融实验

我们在 Amazon 上进行了四组消融，以定位 HardBPR 各设计选择的影响 (表 4)。最核心的对比是 Weight 与 Margin 模式——语义加权 (+48.7%) 显著优于语义边际 (+2.2%)。Margin 在训练初期有效但后期限制了模型对不同难度样本的灵活平衡能力。

此外，我们还探索了两种辅助增强思路：热 $\rightarrow$ 冷协同知识蒸馏 (+Distill) 和语义硬负采样 (+Full)。蒸馏的收益微弱 (仅涉及 4.6% 的冷门物品)，硬负采样反而造成了性能退化。这恰恰

印证了本文的核心论点：语义信号在损失层面是安全有效的聚焦机制，在数据层面却可能破坏粗粒度协同结构的学习。

表 4: Amazon-Book 消融实验结果。

方法	Recall@20	NDCG@20
LightGCN (标准 BPR)	0.0267	0.0126
HardBPR-Weight (本文)	0.0397	0.0224
HardBPR-Margin	0.0283	0.0142
HardBPR + Distill	0.0279	0.0135
HardBPR + Full (硬负采样)	0.0289	0.0140

4.4 模型无关验证

为验证方法的通用性，我们在矩阵分解（MF）和神经图协同过滤（NGCF）两种不同范式的 backbone 上进行了对比。如表 5 所示，MF 上 HardBPR 将 Recall@20 从 0.0423 提升至 0.0478（+13.0%）。NGCF 由于自身的特征变换已在 BPR 优化上趋于饱和，HardBPR 未带来额外提升（Amazon: 0.0881 $\rightarrow$ 0.0846；Steam: 0.1057 $\rightarrow$ 0.1078；Yelp: 0.0834 $\rightarrow$ 0.0835）——这表明 HardBPR 的价值在于弥补标准 BPR 的优化瓶颈，当模型自身已能充分优化 BPR 时，语义加权不再提供额外增益。

表 5: MF 与 NGCF 上的模型无关验证（Amazon-Book, Recall@20）。

Backbone	标准 BPR	+HardBPR (本文)
MF	0.0423	0.0478 (+13.0%)
LightGCN	0.0267	0.0397 (+48.7%)
NGCF	0.0881	0.0846 (-4.0%)

4.5 冷/温/热用户分组分析

图 3 展示了 Amazon 上 LightGCN 及其 HardBPR 版本在冷启动（ ≤ 5 交互）、温用户（6–20）和热用户（ > 20 ）三组上的 Recall@20。HardBPR 在全部三组上均有显著提升：冷用户 0.0253 $\rightarrow$ 0.0346（+36.8%）、温用户 0.0278 $\rightarrow$ 0.0409（+47.1%）、热用户 0.0225 $\rightarrow$ 0.0346（+53.8%）。这一结果表明：HardBPR 的语义感知并非专为冷启动场景设计，而是对全体用户普遍有效的训练增强。

5 结论

本文指出推荐系统的 BPR 训练中存在一个被忽视的瓶颈：随机负采样导致大部分训练迭代浪费在区分语义不相干的“容易负”样本上。我们提出语义感知 BPR（HardBPR），利用冻结的 LLM 物品语义嵌入为每个正负样本对计算语义相似度，并据此重新分配 BPR 损失的样本权重——零额外参数、零推理开销、不改动模型架构。

在三个公开数据集上的实验验证了方法的有效性：

- LightGCN 上 Recall@20 提升 44.7%–101.1%，始终正向且收益与数据稀疏性正相关




图 3: LightGCN vs HardBPR 在不同训练交互组上的 Recall@20 对比。

- MF 上同样有效 (+13.0%), 证明了方法的模型无关性
- 对已充分优化 BPR 的模型 (如 NGCF), HardBPR 不产生额外增益——这界定了方法的适用范围

消融实验揭示了一个反直觉的发现：语义硬负采样（数据层注入）反而有害。我们通过 Information Bottleneck 框架给出了理论解释——数据层语义注入破坏了 BPR 训练的粗粒度压缩结构，而损失层语义加权在不改变压缩结构的前提下重新分配了训练资源。

未来工作将探索语义感知 BPR 在更大规模数据集上的验证，以及自适应 β 调度策略。

参考文献

- [1] Y. Koren, R. Bell, and C. Volinsky. Matrix factorization techniques for recommender systems. *IEEE Computer*, 42(8):30–37, 2009.
- [2] S. Rendle, C. Freudenthaler, Z. Gantner, and L. Schmidt-Thieme. BPR: Bayesian personalized ranking from implicit feedback. In *UAI*, 2009.
- [3] X. He, L. Liao, H. Zhang, L. Nie, X. Hu, and T.-S. Chua. Neural collaborative filtering. In *WWW*, 2017.
- [4] X. He, K. Deng, X. Wang, Y. Li, Y. Zhang, and M. Wang. LightGCN: Simplifying and powering graph convolution network for recommendation. In *SIGIR*, 2020.
- [5] X. Ren, W. Wei, L. Xia, L. Su, S. Cheng, J. Wang, D. Yin, and C. Huang. Representation learning with large language models for recommendation. In *WWW*, 2024.

- [6] W. Zhang, L. Yang, W. Yang, H. P. Zou, Y. Liu, K. Xu, S. Medya, and P. S. Yu. LLMInit: A free lunch from large language models for selective initialization of recommendation. In *EMNLP (Industry Track)*, 2025.
- [7] C. Xue, Y. Lu, C. Yang, and J. Xing. RecMind: LLM-enhanced graph neural networks for personalized consumer recommendations. In *IEEE Conference*, 2026.
- [8] Y. Peng, C. Gao, Y. Zhang, T. Dan, X. Du, H. Luo, Y. Li, and X. Meng. Denoising alignment with large language model for recommendation. *ACM TOIS*, 43:1–35, 2024.
- [9] Y. Li, H. Ju, Z. Song, W. Yang, C. Lu, P. Jiang, and K. Gai. RecGOAT: Graph optimal adaptive transport for LLM-enhanced multimodal recommendation. *arXiv:2602.00682*, 2026.
- [10] J. Meng, R. Zhang, W. Wu, R. Zhang, C. Qin, Q. Zhang, Q. Liu, H. Xiong, and C. Wang. Turning semantics into topology: LLM-driven attribute augmentation for collaborative filtering. *arXiv:2602.21099*, 2026.
- [11] N. Tishby, F. C. Pereira, and W. Bialek. The information bottleneck method. *arXiv:physics/0004057*, 2000.
- [12] K. Shi, J. Zhang, L. Fang, W. Wang, and B. Jing. Enhanced Bayesian personalized ranking for robust hard negative sampling in recommender systems. *arXiv:2403.19276*, 2024.
- [13] J. Jeong et al. Leveraging refined negative feedback with LLM for recommender systems. In *WWW Companion*, 2025.
- [14] R. Raja and A. Vats. Counterfactual risk minimization with IPS-weighted BPR in recommender systems. In *RecSys Workshop*, 2025.