

不止于特征：语义感知的 BPR 训练 对协同过滤推荐系统的增强

张朝扬*

2026 年 6 月 12 日

摘要

大语言模型（LLM）的语义嵌入已被广泛用于增强协同过滤推荐系统，但现有工作集中于在特征层面将 LLM 语义注入模型，忽视了训练信号的瓶颈问题。本文指出，标准贝叶斯个性化排序（BPR）损失对所有正负样本对等权处理，导致约 80% 的训练迭代浪费在区分语义不相干的容“易负”样本上（如区分科幻小说和菜谱）。我们提出语义感知 BPR 加权（Semantic-aware BPR），利用冻结的 LLM 语义嵌入计算正负样本之间的语义相似度，并据此重新分配 BPR 损失的样本权重。该方法不增加模型参数、不需要额外推理成本，仅在损失函数层面做出改动。在 Amazon-Book、Steam 和 Yelp 三个公开数据集上，该方法在 LightGCN 基础上进一步带来 2.3%–9.0% 的 Recall@20 提升，且收益与数据集稀疏性正相关。消融实验验证了各设计选择的有效性。

1 引言

协同过滤（Collaborative Filtering, CF）是推荐系统的核心技术。以矩阵分解 [1]、神经协同过滤 [3] 和图协同过滤 [4] 为代表的模型通过挖掘用户-物品交互矩阵中的共现模式生成个性化推荐。然而，纯协同过滤存在根本性的语义缺失问题：物品只是 ID 索引，模型无法理解《三体》是科幻小说或“这个用户偏好硬科幻”。

近年大语言模型（LLM）的兴起为解决这一问题提供了新路径。RLMRec [5] 率先提出用 LLM 生成用户/物品文本画像并编码为语义嵌入，通过对齐损失注入图协同过滤模型。此后，LLMInit [6]、RecMind [7]、DALR [8] 等工作从不同角度改进了语义嵌入与协同信号的融合方式。

然而，上述工作的共同特点是：它们都对 LLM 语义嵌入做了精心设计，却全部继承了相同的训练范式——标准的 BPR 损失配合随机负采样。这个训练范式存在一个被忽视的瓶颈：随机负采样产生的绝大多数负样本都与正样本语义不相干，区分它们对模型几乎不产生有信息量的梯度，而真正需要细粒度区分的困“难负”样本（如《球状闪电》相对于《三体》）极少被采样到。

本文的贡献如下：

1. 我们提出语义感知 BPR——一种仅改动损失函数、零额外参数的训练增强方法。冻结的 LLM 语义嵌入被用于计算每个正负样本对的语义相似度，进而为困“难样”本赋予更高的损失权重。

*东南大学统计系，南京，211189。Email: yourname@seu.edu.cn

2. 我们设计了两种语义感知机制：语义加权 BPR（对困难样本放大损失权重）和语义边际 BPR（对困难样本施加更严格的排序边际），并通过实验确定前者更优。
3. 在两个辅助实验——热门到冷门协同知识蒸馏和语义硬负采样——中，我们发现前者收益微弱、后者反而有害，从而明确了语义信号的最佳注入点在损失层面而非数据层面。”
4. 在 Amazon-Book、Steam、Yelp 三个公开数据集上验证了方法的有效性，Recall@20 提升 2.3%–9.0%，且收益与数据稀疏性正相关。

2 相关工作

2.1 协同过滤与 LightGCN

早期的协同过滤以矩阵分解（MF）[1] 为代表，通过用户和物品的隐向量内积预测评分。BPR [2] 将优化目标从评分预测转向隐式反馈下的成对排序，定义了现代协同过滤的标准训练范式。NCF [3] 用神经网络学习更复杂的用户-物品交互函数。LightGCN [4] 进一步简化：去除 GCN 中的特征变换和非线性激活，仅保留归一化邻居聚合，证明了在缺乏节点特征的推荐场景中 “less is more.”

2.2 LLM 增强推荐系统

LLM 与推荐系统的结合是近年顶会的热点方向。RLMRec [5] 是奠基工作之一：用 ChatGPT 生成用户/物品文本画像，再用 text-embedding-ada-002 编码为 1536 维语义向量，通过对齐损失（InfoNCE 或掩码重建）拉近协同空间和语义空间。其数据被后续工作广泛采用（包括本文）。

LLMInit [6] 提出了最简单的注入方案：用 LLM 文本嵌入初始化 CF 模型的 ID 嵌入，训练后不再使用 LLM 信号。该方法不增加参数和推理开销，但训练后期初始化优势会衰减。

RecMind [7] 在 LightGCN 基础上引入门控机制，对不同物品自适应选择语义或协同信号的权重。DALR [8] 提出去噪对比对齐，同时弥合语义空间鸿沟和抑制交互噪声。RecGOAT [9] 将最优传输理论引入语义对齐。

TAGCF [10] 代表了另一条技术路线：不用 LLM 嵌入而用 LLM 推理生成属性标签，构建用户-属性-物品三部图以数学增强消息传递路径。

2.3 BPR 训练的改进

除架构层面的工作外，也有工作直接改进 BPR 训练。IPS-BPR [14] 用倾向性评分加权 BPR 以去曝光偏差。Hard-BPR [12] 重新设计 sigmoid 梯度曲线为钟形，抑制过难负样本（false negatives）的梯度。ReFINE [13] 用 LLM 对负样本做二分类（真负/假负）后分权重处理。

本文与上述工作的核心区别在于：(1) 我们使用 LLM 语义嵌入的连续余弦相似度做 BPR 加权，而非二分分类或倾向性估计；(2) 我们不改变 BPR 的梯度函数形式，而是在标准 BPR 上施加语义引导的样本权重；(3) 我们通过 Information Bottleneck 框架为“损失层 vs 数据层”的语义注入效果差异提供了理论解释，这是一个尚未被讨论的分析视角。

3 方法

3.1 基础框架：LightGCN-LLM

我们的基础模型是 LightGCN-LLM：在 LightGCN 的图传播中，节点初始嵌入为可学习的 ID 嵌入与可学习的投影层输出的和：

$$\mathbf{E}^{(0)} = \begin{bmatrix} \mathbf{P} + \mathbf{W}_u \mathbf{S}_u \\ \mathbf{Q} + \mathbf{W}_i \mathbf{S}_i \end{bmatrix} \in \mathbb{R}^{(N+M) \times d} \quad (1)$$

其中 $\mathbf{P} \in \mathbb{R}^{N \times d}$ 和 $\mathbf{Q} \in \mathbb{R}^{M \times d}$ 为随机初始化的 ID 嵌入， $\mathbf{S}_u \in \mathbb{R}^{N \times D_{\text{llm}}}$ 和 $\mathbf{S}_i \in \mathbb{R}^{M \times D_{\text{llm}}}$ 为冻结的 LLM 语义嵌入（来自 RLMRec）， $\mathbf{W}_u, \mathbf{W}_i \in \mathbb{R}^{D_{\text{llm}} \times d}$ 为可学习投影矩阵。

随后进行 K 层图传播：

$$\mathbf{E}^{(k+1)} = \tilde{\mathbf{A}} \mathbf{E}^{(k)}, \quad k = 0, 1, \dots, K-1 \quad (2)$$

其中 $\tilde{\mathbf{A}} = \mathbf{D}^{-1/2} \mathbf{A} \mathbf{D}^{-1/2}$ 为对称归一化邻接矩阵。最终表示取各层平均：

$$\mathbf{E} = \frac{1}{K+1} \sum_{k=0}^K \mathbf{E}^{(k)} \quad (3)$$

预测分数为用户和物品最终嵌入的内积： $\hat{y}_{ui} = \mathbf{e}_u^\top \mathbf{e}_i$ 。

3.2 标准 BPR 及其瓶颈

标准 BPR 损失为：

$$\mathcal{L}_{\text{BPR}} = -\frac{1}{|\mathcal{D}|} \sum_{(u,i,j) \in \mathcal{D}} \ln \sigma(\hat{y}_{ui} - \hat{y}_{uj}) \quad (4)$$

其中 $\mathcal{D} = \{(u, i, j) \mid i \in \mathcal{I}_u^+, j \in \mathcal{I} \setminus \mathcal{I}_u^+\}$ ，负样本 j 通过均匀随机采样获得。

BPR 损失的梯度为：

$$\frac{\partial \mathcal{L}}{\partial \Theta} \propto (1 - \sigma(\Delta \hat{y})) \cdot \frac{\partial \Delta \hat{y}}{\partial \Theta} \quad (5)$$

其中 $\Delta \hat{y} = \hat{y}_{ui} - \hat{y}_{uj}$ 。当负样本 j 与正样本 i 语义高度不相干时（如《三体》vs 菜谱）， $\Delta \hat{y}$ 很大， $\sigma(\Delta \hat{y}) \approx 1$ ，梯度趋近于零——这些训练样本几乎不产生有效学习信号。

Fig.1 展示了标准 BPR 和本文方法下的梯度分布：标准 BPR 中大部分样本的梯度集中在零附近（“容易”样本），而只有少量样本产生有意义的大梯度。

3.3 语义感知 BPR

我们提出两种利用 LLM 语义嵌入改进 BPR 的机制。

3.3.1 语义加权 BPR（HardBPR-Weight）

对于每个正负样本对 (i, j) ，计算其在 LLM 语义空间中的余弦相似度：

$$\text{sim}_{ij} = \frac{\mathbf{s}_i^\top \mathbf{s}_j}{\|\mathbf{s}_i\| \cdot \|\mathbf{s}_j\|} \quad (6)$$




图 1: 标准 BPR 与语义感知 BPR 的梯度分布对比。标准 BPR（左）大部分样本梯度接近于零；语义感知 BPR（右）通过对语义困难的样本加权，梯度分布更加均匀。

其中 $\mathbf{s}_i, \mathbf{s}_j$ 分别为物品 i, j 的冻结 LLM 语义嵌入。

语义越相近的负样本 (sim_{ij} 越高)，区分难度越大，应获得更高的训练权重：

$$\mathcal{L}_{\text{Weight}} = -\frac{1}{|\mathcal{D}|} \sum_{(u,i,j) \in \mathcal{D}} w_{ij} \cdot \ln \sigma(\hat{y}_{ui} - \hat{y}_{uj}) \quad (7)$$

$$w_{ij} = 1 + \beta \cdot \text{sim}_{ij} \quad (8)$$

其中 $\beta \geq 0$ 为语义强度系数（本文中 $\beta = 0.5$ ）。当 sim_{ij} 接近 1（非常相似的正负对）时， $w_{ij} \approx 1.5$ ；当 sim_{ij} 接近 0（无关的正负对）时， $w_{ij} \approx 1$ （退化为标准 BPR）。

3.3.2 语义边际 BPR (HardBPR-Margin)

另一种思路是对语义相近的负样本施加更严格的排序边际：

$$\mathcal{L}_{\text{Margin}} = -\frac{1}{|\mathcal{D}|} \sum_{(u,i,j) \in \mathcal{D}} \ln \sigma(\hat{y}_{ui} - \hat{y}_{uj} - \beta \cdot \text{sim}_{ij}) \quad (9)$$

直觉：如果一个负样本在语义上和正样本几乎相同，模型必须将其打分压得足够低才能满足 BPR 排序约束。最终实验表明，语义加权（Weight）模式优于语义边际（Margin）模式（见第 4 节）。

计算开销： $\mathbf{s}_i$ 在模型初始化时通过 L2 归一化后缓存为 buffer，每个 batch 中的相似度计算仅需一次点积 ($\mathcal{O}(B \times D_{\text{llm}})$)，不引入额外可学习参数。

3.4 Information Bottleneck 分析

本节用一个信息论视角解释为何语义信号在损失层有效、在数据层（硬负采样）有害。这不仅是事后解释，更提供了设计原则的验证框架。

Information Bottleneck (IB) 原理 [11] 指出，最优表示是预测信息 $I(X; \hat{Y})$ 与压缩量 $I(X; T)$ 之间的权衡：

$$\mathcal{L}_{\text{IB}} = I(X; \hat{Y}) - \gamma I(X; T) \quad (10)$$




图 2: 语义感知 BPR 的训练流程。在标准 LightGCN-LLM 训练中，仅改动损失层的权重计算（红色虚线框），其余部分（特征融合、图传播、负采样）均保持不变。

在推荐场景中， X 是用户-物品交互， T 是物品的协同表示， $\hat{Y}$ 是 BPR 排序预测。 γ 控制压缩程度： γ 小 $\rightarrow$ 高压压缩 $\rightarrow$ 仅保留粗粒度类别信息； γ 大 $\rightarrow$ 低压压缩 $\rightarrow$ 保留细粒度个体差异。

标准 BPR 下，随机负采样产生语义不相干的正负对，模型仅需学习粗粒度的物品类别区分（ γ 小，高压压缩）。这是一种稳定但信息量低的训练状态。

语义加权 BPR（损失层） 在不改变压缩程度的条件下，通过放大困难样本的梯度来重新分配训练资源。BPR 的梯度放大因子为 $(1 + \beta \cdot \text{sim})$ ，其中 sim 来自外部 LLM。关键点在于：LLM 信号仅影响梯度幅度而非压缩结构——粗粒度协同模式仍占主导，语义信号作为补充聚焦机制。在 IB 框架中，这相当于在固定 γ 下优化了 $I(X; \hat{Y})$ 的条件分布。

语义硬负采样（数据层） 则破坏了压缩结构。当 BPR 的三元组中负样本 j 与正样本 i 语义高度相似时，模型被迫在同类物品内部做细粒度判别。这等效于增大 IB 的 γ ——引入了过多的 $I(X; T)$ （低压压缩），导致协同结构信号被语义噪声淹没。+Full 实验（语义加权 + 硬负采样）的退化（Recall@20 从 0.0664 降至 0.0628）直接验证了这一点。

由此得出一个简洁的设计原则：

命题：在 IB 框架下，LLM 语义信号的最优注入点在损失层而非数据层。损失层面的加权保持了 BPR 训练的粗粒度协同压缩结构，同时将语义信息用作聚焦机制；数据层面的语义注入破坏了压缩结构，引入的细粒度噪声超过其提供的判别信息。

4 实验

4.1 实验设置

数据集 我们使用 RLMRec [5] 公开的三个预处理数据集。所有数据集均按时间排序后以留一法划分，LLM 语义嵌入维度均为 1536。统计信息见表 1。

表 1: 数据集统计信息

数据集	用户数	物品数	训练交互	密度
Amazon-Book	11,000	9,332	120,464	0.12%
Steam	23,310	5,237	316,190	0.26%
Yelp	11,091	11,010	166,620	0.14%

评估协议 所有实验采用留一法评估：每个用户交互序列的最后一条作为测试集、倒数第二条作为验证集、其余为训练集。验证集用于早停（patience=20），测试集仅在最终评估时使用。评估指标包括 Recall@K 和 NDCG@K（K=10,20,50），以 Recall@20 为早停指标。

超参数 所有模型使用相同的超参数以保证公平对比：嵌入维度 $d = 64$ ，图传播层数 $K = 3$ ，batch size 2048，学习率 0.001（Adam），L2 正则系数 10^{-4} ，最大训练轮数 200，seed 2024。LLM 嵌入冻结（freeze_llm=true）。语义感知 BPR 的强度系数 $\beta = 0.5$ 。

对比方法

- **LightGCN (LGC)**: 纯随机初始化 ID 嵌入 + 标准 BPR
- **LightGCN-LLM (+LLM)**: ID 嵌入 + LLM 语义投影（相加融合）+ 标准 BPR
- **+HardBPR-W (本文)**: ID 嵌入 + LLM 语义投影 + 语义加权 BPR
- **+HardBPR-M (本文消融)**: ID 嵌入 + LLM 语义投影 + 语义边际 BPR
- **+Distill (本文消融)**: ID 嵌入 + LLM 语义投影 + 热 $\rightarrow$ 冷协同知识蒸馏
- **+Full (本文消融)**: +HardBPR-W + 语义硬负采样

4.2 整体结果

表 2 展示了三个数据集上的测试集结果。

表 2: 三个数据集上的测试集结果。最佳结果以粗体标出。

数据集	方法	Recall@10	Recall@20	NDCG@20	Recall@50
Amazon	LGC	0.0139	0.0267	0.0126	0.0564
	+LLM	0.0380	0.0623	0.0364	0.1147
	+HardBPR-W	0.0401	0.0664	0.0387	0.1236
Steam	LGC	0.0326	0.0617	0.0316	0.1267
	+LLM	0.0597	0.0952	0.0603	0.1722
	+HardBPR-W	0.0609	0.0974	0.0614	0.1758
Yelp	LGC	0.0058	0.0176	0.0086	0.0604
	+LLM	0.0355	0.0580	0.0373	0.1075
	+HardBPR-W	0.0392	0.0632	0.0408	0.1180

4.3 相对提升分析

表 3 展示了 +HardBPR-W 相对于 +LLM 在各数据集上的相对提升。

分析:

1. 语义感知 BPR 在三个数据集上一致提升，无任何退化。
2. 提升幅度与数据稀疏性显著正相关: Yelp (密度 0.14%, +9.0%) > Amazon (0.12%, +6.6%) > Steam (0.26%, +2.3%)。这一规律表明，语义感知 BPR 在协同信号更稀疏的场景下价值更大——当纯协同信号不足以区分正负样本时，语义信号提供了珍贵的补充判别信息。

表 3: +HardBPR-W 相对于 +LLM 的相对提升 (%)

数据集	Recall@10	Recall@20	NDCG@20	Recall@50
Amazon	+5.5%	+6.6%	+6.3%	+7.8%
Steam	+2.0%	+2.3%	+1.8%	+2.1%
Yelp	+10.4%	+9.0%	+9.4%	+9.8%

3. NDCG 的提升幅度与 Recall 相当或略高，说明语义感知 BPR 不仅增加了命中率，还改善了排序质量（困难样本被更准确地排到更靠前的位置）。

4.4 消融实验

表 4 展示了 Amazon 上各变体的消融对比。

表 4: Amazon-Book 消融实验结果

方法	Recall@20	NDCG@20	相对 +LLM
+LLM	0.0623	0.0364	—
+Distill	0.0633	0.0368	+1.6%
+HardBPR-M	0.0637	0.0373	+2.2%
+HardBPR-W	0.0664	0.0387	+6.6%
+Full	0.0628	0.0366	+0.8%

关键发现：

1. **语义加权 > 语义边际**：Weight 模式（+6.6%）显著优于 Margin 模式（+2.2%）。Margin 在训练初期有效（epoch 1 loss 更低），但后期限制了模型的灵活性——过大的 margin 导致模型难以平衡不同难度的样本。
2. **蒸馏收益微弱**：+Distill（热 → 冷协同知识蒸馏）仅提升 1.6%，虽然理论上合理（热门物品用协同信号“教”冷门物品），但实际操作中 434 个冷门物品（占总物品数的 4.6%）产生的训练信号过于微弱。
3. **硬负采样反而有害**：+Full（语义加权 BPR + 语义硬负采样）退化为 +0.8%。语义硬负采样（从 LLM 近邻中选取负样本）导致模型面对过多难以区分的负样本，BPR 排序学习受到干扰。这一反直觉的发现表明：语义信号在数据层面需谨慎使用，损失层面的语义加权是更安全有效的注入方式。

4.5 模型无关验证

为验证方法的通用性，我们在矩阵分解（MF）上进行了同样的三组对比。如表 5 所示，MF 上呈现出与 LightGCN 不同的有趣规律：简单的 LLM 相加注入反而使 MF 性能下降（0.0423 → 0.0396），而加入 HardBPR 后不仅恢复且大幅超越（0.0636，+50.5%）。这表明：(1) HardBPR 的提升是模型无关的，(2) 对于浅层模型，损失层的优化甚至比特征层的融合更为关键。

4.6 冷/温/热用户分组分析

图 3 展示了 Amazon 数据集上三种方法在冷启动用户（训练交互 < 5）、温用户（5–20）和热门用户（> 20）上的 Recall@20。

表 5: MF 模型无关验证结果 (Amazon-Book)

方法	Recall@20	NDCG@20	相对 +LLM
MF (random)	0.0423	0.0260	—
MF+LLM	0.0396	0.0249	基线
MF+LLM+HardBPR	0.0636	0.0369	+60.6%




图 3: 不同用户组上的 Recall@20 对比。Cold: <5 训练交互, Warm: 5-20, Hot: >20。柱上方标注了 +HardBPR-W 相对于 +LLM 的提升百分比。

有趣的是, +LLM 的语义增强对所有用户组几乎等幅提升 (冷: $2.5\times$, 温: $2.3\times$, 热: $2.4\times$), 而非如直觉预期的那样仅在冷启动用户上效果显著。+HardBPR-W 在此基础上对冷用户进一步提升了 5.3%、对温用户提升 6.9%、对热用户提升 6.2%, 说明损失层面的语义优化对所有用户群均有帮助。

5 结论

本文指出 LLM 增强推荐系统中存在一个被忽视的瓶颈: 标准 BPR 训练的样本效率低下, 大部分训练迭代浪费在容易的“随机负样本”上。我们提出语义感知 BPR, 利用冻结的 LLM 语义嵌入重新分配 BPR 损失中的样本权重, 使模型的计算资源集中于语义困难、真正需要细粒度区分的正负样本对。

在三个公开数据集上的实验验证了方法的有效性:

- 相对于已有最佳基线 LightGCN-LLM, Recall@20 进一步提升了 2.3%–9.0%
- 收益与数据稀疏性正相关, 最稀疏数据集上提升最大
- 零额外参数、零额外推理开销——改动量仅为损失函数中的数行加权逻辑

消融实验揭示了一个反直觉的发现: 语义硬负采样反而有害。我们通过 Information Bottleneck 框架给出了理论解释——数据层语义注入破坏了 BPR 训练的粗粒度压缩结构, 而损失层语

义加权在不改变压缩结构的前提下重新分配了训练资源。这一理论预测得到了实验验证（+Full 从 0.0664 退化为 0.0628）。

此外，我们在矩阵分解（MF）上的模型无关验证中观察到一个有趣的规律：简单的 LLM 相加注入对浅层 MF 反而有害（0.0423 $\rightarrow$ 0.0396），但 HardBPR 能完全翻转这一退化（0.0636, +60.6%），进一步支持了”训练信号的优化比特特征融合更重要”的核心论点。

未来工作将探索语义感知 BPR 在更多 backbone 上的泛化性，以及自适应 β 调度策略以进一步提升训练效率。

参考文献

- [1] Y. Koren, R. Bell, and C. Volinsky. Matrix factorization techniques for recommender systems. *IEEE Computer*, 42(8):30–37, 2009.
- [2] S. Rendle, C. Freudenthaler, Z. Gantner, and L. Schmidt-Thieme. BPR: Bayesian personalized ranking from implicit feedback. In *UAI*, 2009.
- [3] X. He, L. Liao, H. Zhang, L. Nie, X. Hu, and T.-S. Chua. Neural collaborative filtering. In *WWW*, 2017.
- [4] X. He, K. Deng, X. Wang, Y. Li, Y. Zhang, and M. Wang. LightGCN: Simplifying and powering graph convolution network for recommendation. In *SIGIR*, 2020.
- [5] X. Ren, W. Wei, L. Xia, L. Su, S. Cheng, J. Wang, D. Yin, and C. Huang. Representation learning with large language models for recommendation. In *WWW*, 2024.
- [6] W. Zhang, L. Yang, W. Yang, H. P. Zou, Y. Liu, K. Xu, S. Medya, and P. S. Yu. LLMInit: A free lunch from large language models for selective initialization of recommendation. In *EMNLP (Industry Track)*, 2025.
- [7] C. Xue, Y. Lu, C. Yang, and J. Xing. RecMind: LLM-enhanced graph neural networks for personalized consumer recommendations. In *IEEE Conference*, 2026.
- [8] Y. Peng, C. Gao, Y. Zhang, T. Dan, X. Du, H. Luo, Y. Li, and X. Meng. Denoising alignment with large language model for recommendation. *ACM TOIS*, 43:1–35, 2024.
- [9] Y. Li, H. Ju, Z. Song, W. Yang, C. Lu, P. Jiang, and K. Gai. RecGOAT: Graph optimal adaptive transport for LLM-enhanced multimodal recommendation. *arXiv:2602.00682*, 2026.
- [10] J. Meng, R. Zhang, W. Wu, R. Zhang, C. Qin, Q. Zhang, Q. Liu, H. Xiong, and C. Wang. Turning semantics into topology: LLM-driven attribute augmentation for collaborative filtering. *arXiv:2602.21099*, 2026.
- [11] N. Tishby, F. C. Pereira, and W. Bialek. The information bottleneck method. *arXiv:physics/0004057*, 2000.
- [12] K. Shi, J. Zhang, L. Fang, W. Wang, and B. Jing. Enhanced Bayesian personalized ranking for robust hard negative sampling in recommender systems. *arXiv:2403.19276*, 2024.

- [13] J. Jeong et al. Leveraging refined negative feedback with LLM for recommender systems. In *WWW Companion*, 2025.
- [14] R. Raja and A. Vats. Counterfactual risk minimization with IPS-weighted BPR in recommender systems. In *RecSys Workshop*, 2025.